skill评估优化

1. skill创建

Skill Creator 将技能创建分为五个关键阶段，形成一个循环：

1. **确定意图 (Decide)**：明确技能要做什么，触发场景是什么。
2. **编写草案 (Draft)**：编写 `SKILL.md` 文件，包含 YAML 元数据和 Markdown 指令。
3. **运行测试 (Test)**：创建测试用例，同时运行“有技能辅助”和“无技能（基准）”的对比实验。
4. **评估结果 (Evaluate)**：
   - **定性**：通过 `eval-viewer` 生成可视化界面，让用户亲自看结果并写反馈。
   - **定量**：运行断言（Assertions），计算通过率、耗时和 Token 消耗。
5. **迭代优化 (Iterate)**：根据反馈修改技能，再次运行测试，直到满意。

代码块

```
recsys-workflow-skill/
├── SKILL.md                          # 主编排逻辑（324行）
└── references/
    ├── phase2_math_templates.md      # 数学建模模板库
    └── phase3_code_templates.md      # 工程代码模板库
```

写测试用例（Evals）- 跑基准测试（Benchmark）- 对比不同版本（A/B Test）- 自动优化描述（Trigger Tuning）

大致评估优化内容： 主要两类：结构类和内容类

1. 功能正确性：能不能**完成预设任务**
2. 意图识别准确率：用户 query 能不能**正确触发该 Skill**
3. 响应质量：答案准确、完整、简洁
4. 交互与上下文能力：多轮对话是否记得上文
5. 性能指标：

调用成功率

平均响应时延

资源占用、稳定性

6. 安全与合规

方法：自动 和 llm-judge：

1. 自动化评估：写**测试用例集**（正常 / 异常 / 边界），批量跑 Skill

2.LLM-as-Judge（大模型当裁判，现在最主流）

3.人工评估

4.线上 A/B 测试

5.边界 & 对抗鲁棒性测试

6.基准数据集 / 标准化评测

2. 优化方法 (Optimization Methods)

Skill 的优化分为内部逻辑优化和外部触发机制优化。

A. 内容与逻辑优化

1.从反馈中总结经验。从反馈中泛化（避免过拟合）

2.保持提示简洁。精简 Prompt

3.解释原因。解释“为什么”要这么做以利用大模型的心智理论

4.寻找测试用例中的重复操作。将重复的工作封装为 `scripts/` 中的独立脚本。

人类或 Analyzer 的诊断反馈数据:

具体实现：

对于客观的，打断言，测试结构正确性；主观的，llm jude

断言定义：好的断言必须是客观且可验证的。主观的技能（如写作风格、设计质量）不适合使用断言，而应该由人工进行定性评估。

没有输出doc文件，使用skill-creator优化这个上面那个pdf总结的skill

#	断言	旧版	新版
1	含 □ 特殊字符的 PDF 能成功生成 docx	❌ 崩溃	✅ 40KB
2	含数学符号 \ud835 的 PDF 能成功生成 docx	❌ 崩溃	✅ 38KB
3	生成的 docx 含 Word 标题样式（Heading 1/2/3）	❌ 根本没文件	✅ H1/H2/H3
4	生成的 docx 含列表样式（List Bullet）	❌ 根本没文件	✅ 有

新版通过率：4/4（100%） | 旧版通过率：0/4（0%）

图片是目前新版输出的摘要里面的内容，对表格样式的支持不是很好，同时摘要里面将创新点放在了最后，我觉得这样的排版不是很合适。请优化。使用skill-creator进行优化前后对比

断言	新版	旧版
docx 成功生成	✅	✅
含真实 Word 表格	✅ 1个，7行×2列	❌ 0个
表格无原始竖线字符	✅	✅（但根本没写表格，不算真正通过）
创新点位置 ≤ 第4节	✅ 第2节	❌ 第8节

B. 触发描述自动优化 (Description Optimization)

`在优化 Description 时，测试 Claude 遇到各种模糊或相似的提问时，能否准确地“唤醒”并调用 Skill。`

- **测试集构建**：生成约 20 个查询，混合“应触发 (should-trigger)”和“不应触发 (should-not-trigger，通常是具有迷惑性的相邻领域查询)”的用例。通过 `assets/eval_review.html` 让用户确认测试集。

```
工作原理：
①准备 20 条查询（10 条应触发 + 10 条不应触发）
②对每条查询运行 claude -p，检测是否调用了 Skill 工具
③计算 precision/recall/accuracy
④把失败案例传给 Claude，要求生成改进后的 description
⑤重新评估新描述 → 循环最多 5 次
⑥以测试集（holdout 40%）得分选出最优描述
```

描述优化：此部分需要 `claude` CLI 工具，特别是 `claude -p`，这仅在 Claude Code 中可用。如果在 Claude.ai 上请跳过。`_call_claude` 函数直接使用了 `subprocess.run(["claude", "-p", "--output-format", "text"], ...)` 来向模型发送 Prompt 并获取修改后的 Description。

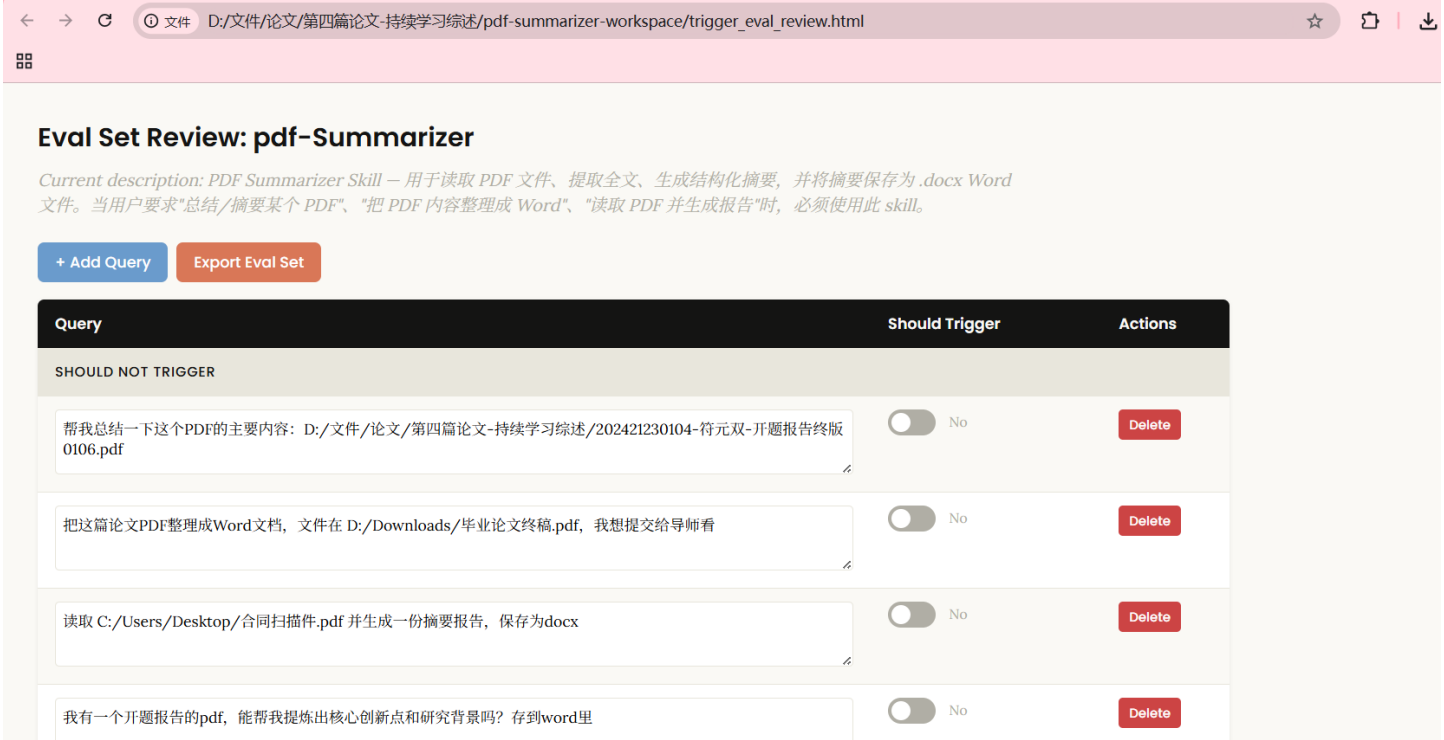

代码块

```
[
  {
    "query": "我刚看到腾讯广告的推荐系统赛题，赛题是'Towards Unifying Sequence Modeling'，能帮我解释一下这道题到底要解决什么问题吗？",
    "should_trigger": true
  },
  {
    "query": "推荐系统竞赛中，如何把序列建模和特征交互融合在一个Recommendation Block里？",
    "should_trigger": true
  },
  {
    "query": "帮我设计一个实验，验证推荐系统中单一Transformer Block的Scaling Law曲线，最大参数量要测到large级别。",
    "should_trigger": true
  },
  {
    "query": "我想写一个推荐系统，用协同过滤算法（Collaborative Filtering）怎么给用户推荐商品？",
    "should_trigger": false,
    "_comment": "负样本：虽然是推荐系统，但是通用基础算法，不涉及本赛题的序列与特征统一，不应触发该高级Skill。"
  },
  {
    "query": "帮我总结一下《Attention is All You Need》这篇论文里Transformer的位置编码是怎么设计的。",
```

```
    "should_trigger": false,
    "_comment": "负样本：虽然提到了Transformer和位置编码，但属于通用深度学习知识，与推荐赛题无关。"
  },
  {
    "query": "腾讯广告的点击率预估业务中，一般怎么处理缺失值？",
    "should_trigger": false,
    "_comment": "负样本（高难度干扰项）：提到了腾讯广告，但属于通用CTR预估实战，除非用户明确提及赛题或Recommendation Block，否则不应触发。"
  }
]
```

3. 评估：

1.

评估环节分为**定量自动评估**、**定性人工评估**以及**盲测对比**，这是整个框架最核心的质量把控部分。

A. 自动定量评分 (Automated Grading)

- **执行与评估文件**：由 Grader Agent 根据 `agents/grader.md` 提取测试输出并进行评分。其结果会输出为 `grading.json`。
- **评估指标**：
  - **通过率 (Pass Rate)**：基于客观断言的通过比例（`passed` / `total`）：

    量化方式：大模型阅卷（单题判定）+（计算比例）。大模型如何评分（定性判决）： 系统会生成一个叫 Grader 的大模型 Agent，它会拿着写好的断言（Expectations）去对比生成的输出和运行日志。在 `skill-creator/agents/grader.md` 文件中，写死了大模型评分的 Prompt 指令：

断言	iter-3	iter-4
docx 文件成功生成（开题报告）	✅ PASS	✅ PASS
文档含真实 Word 表格（开题报告）	✅ PASS（1个）	✅ PASS（2个）
无原始竖线字符段落（开题报告）	✅ PASS	✅ PASS
核心创新点 ≤ 第4节（开题报告）	✅ PASS（第2节）	✅ PASS（第2节）
docx 文件成功生成（引言）	✅ PASS	✅ PASS
文档含 Word 标题样式（引言）	✅ PASS	✅ PASS
文档含列表样式（引言）	✅ PASS	✅ PASS
提取不崩溃（引言）	✅ PASS	✅ PASS
总通过率	8/8（100%）	8/8（100%）

三次优化的通过率演进

```
v1（原始）        v2（编码修复）      v3（表格+顺序）      v3 再次运行
 0/6   →          6/6      →          4/4       →       8/8
 (0%)             (100%)              (100%)             (100%)
```

`PASS when: The transcript or outputs clearly demonstrate the expectation is true...`（当日志或输出明确证明预期为真时给予 PASS）

`FAIL when: No evidence found for the expectation...`（找不到证据或只是表面满足时给予 FAIL） Grader Agent 评判后，会将每条断言的 True/False 结果保存在 `grading.json` 中。

代码块

```
{
  "expectations": [
    {
      "text": "The output includes the name 'John Smith'",
      "passed": true,
      "evidence": "Found in transcript Step 3: 'Extracted names: John Smith, Sarah Johnson'"
    },
    {
      "text": "The spreadsheet has a SUM formula in cell B10",
      "passed": false,
      "evidence": "No spreadsheet was created. The output was a text file."
    },
    {
```

```
      "text": "The assistant used the skill's OCR script",
      "passed": true,
      "evidence": "Transcript Step 2 shows: 'Tool: Bash - python ocr_script.py image.png'"
    }
  ],
  "summary": {
    "passed": 2,
    "failed": 1,
    "total": 3,
    "pass_rate": 0.67
  },
  "execution_metrics": {
    "tool_calls": {
      "Read": 5,
      "Write": 2,
      "Bash": 8
    },
    "total_tool_calls": 15,
    "total_steps": 6,
    "errors_encountered": 0,
    "output_chars": 12450,
    "transcript_chars": 3200
  },
  "timing": {
    "executor_duration_seconds": 165.0,
    "grader_duration_seconds": 26.0,
    "total_duration_seconds": 191.0
  },
  "claims": [
    {
      "claim": "The form has 12 fillable fields",
      "type": "factual",
      "verified": true,
      "evidence": "Counted 12 fields in field_info.json"
    },
    {
      "claim": "All required fields were populated",
      "type": "quality",
      "verified": false,
      "evidence": "Reference section was left blank despite data being available"
    }
  ],
  "user_notes_summary": {
    "uncertainties": ["Used 2023 data, may be stale"],
    "needs_review": [],
```

```
      "workarounds": ["Fell back to text overlay for non-fillable fields"]
    },
    "eval_feedback": {
      "suggestions": [
        {
          "assertion": "The output includes the name 'John Smith'",
          "reason": "A hallucinated document that mentions the name would also pass — consider checking it appears as the primary contact with matching phone and email from the input"
        },
        {
          "reason": "No assertion checks whether the extracted phone numbers match the input — I observed incorrect numbers in the output that went uncaught"
        }
      ],
      "overall": "Assertions check presence but not correctness. Consider adding content verification."
    }
  }
```

代码如何量化（定量计算）： 在 `skill-creator/scripts/aggregate_benchmark.py` 脚本中，Python 代码会读取这些 True/False，计算单次运行的通过率，并使用 `calculate_stats()` 函数计算所有运行轮次的平均值和标准差

- **时间 (Time)**：系统会捕获任务耗时，存储在 `timing.json` 中的 `total_duration_seconds`。

迭代	测试用例	配置	耗时
iteration-1	eval-encoding-special-chars	with_skill	106.5 秒
iteration-1	eval-format-quality	with_skill	74.0 秒
iteration-1	old_skill（两个）	–	崩溃（几秒内报错）
iteration-4	eval-kaiti-report	with_skill	91.0 秒
iteration-4	eval-yinyan	with_skill	54.0 秒

- **Token消耗 (Tokens)**：总 Token 使用量或输出字符数 (`output_chars`)。

迭代	测试用例	配置	Token
iteration-1	eval-encoding-special-chars	with_skill（新版）	40,000
iteration-1	eval-format-quality	with_skill（新版）	25,938
iteration-1	eval-encoding-special-chars	old_skill（旧版）	崩溃，未完成
iteration-1	eval-format-quality	old_skill（旧版）	崩溃，未完成
iteration-2	–	–	未记录（手动运行）
iteration-3	eval-kaiti-report	with_skill	0（未记录）
iteration-3	eval-yinyan	with_skill	0（未记录）
iteration-4	eval-kaiti-report	with_skill	37,869
iteration-4	eval-yinyan	with_skill	15,905

当每个 subagent 任务完成时，你会收到一个包含 `total_tokens` 和 `duration_ms` 的通知。必须立即将此数据保存到运行目录中的 `timing.json` 中”。这是一个只出现一次的底层系统事件回调。

- **工具调用与错误**：总工具调用次数 (`tool_calls`) 以及执行中遇到的错误数 (`errors_encountered`)。

Agent 框架（Executor）在运行过程中真实记录的统计数据。

当大模型执行任务时，它每一次调用工具（如 Read、Write、Bash 等）和发生的报错，都会被执行环境捕获，并写入到运行目录下的 `outputs/metrics.json` 文件中

该脚本会读取所有的 `grading.json` 和 `timing.json` ，计算每个配置（有 Skill vs 无 Skill）下各项指标的**均值 (mean)**、**标准差 (stddev)**、**最小值**和**最大值**，并计算两者之间的 **Delta (差值)**。最终生成 `benchmark.json` 和可视化的 `benchmark.md` 。

C. 定性人工评估 (Qualitative Human Review)

- **执行文件**： `eval-viewer/generate_review.py` 和对应的 `viewer.html` 。
- **方法**：脚本会启动一个本地的 HTML 浏览器视图，将提示词、生成的输出文件、格式化成绩和基准测试统计并排展示。用户可以通过 UI 点击浏览各个输出，并在文本框中留下主观反馈，反馈会实时自动保存到工作区的 `feedback.json` 中。

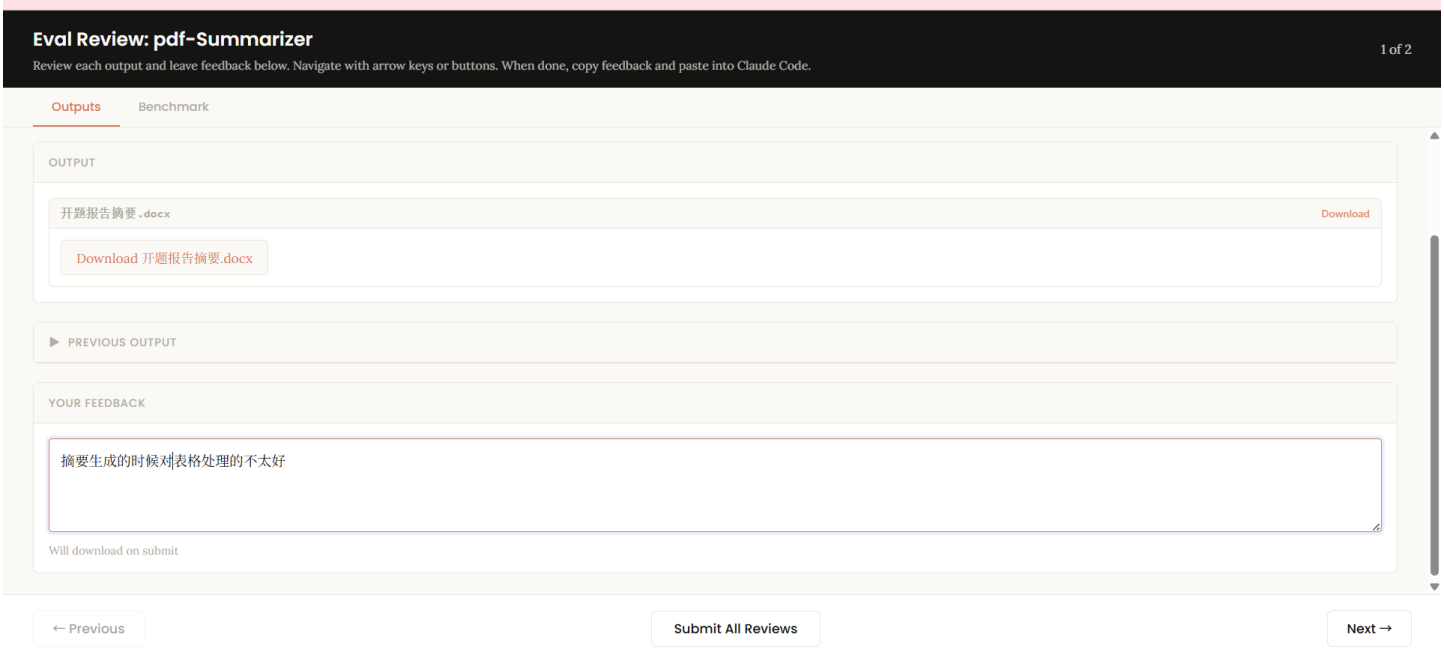

D. 盲测对比与深度分析 (Blind Comparison - 高级评估)

- **比较方法**：由 Blind Comparator Agent (`agents/comparator.md`) 在不知道哪个输出是由哪个配置生成的情况下，对两个输出（A和B）进行打分。
- **评分量表 (Rubric, 1-5分)**：
  - **内容 (Content)**：正确性 (Correctness)、完整性 (Completeness)、准确性 (Accuracy)。
  - **结构 (Structure)**：组织 (Organization)、格式 (Formatting)、可用性 (Usability)。
- **结果分析**：Post-hoc Analyzer Agent (`agents/analyzer.md`) 会在比较结束后“揭盲”，分析胜者获胜的原因，对“指令遵循度 (Instruction Following)”进行 1-10 分的打分，并针对失败者提出具体的改进建议（涉及指令、工具、示例、错误处理等分类）。

Content Rubric (what the output contains):

Criterion	1 (Poor)	3 (Acceptable)	5 (Excellent)
Correctness	Major errors	Minor errors	Fully correct
Completeness	Missing key elements	Mostly complete	All elements present
Accuracy	Significant inaccuracies	Minor inaccuracies	Accurate throughout

Structure Rubric (how the output is organized):

Criterion	1 (Poor)	3 (Acceptable)	5 (Excellent)
Organization	Disorganized	Reasonably organized	Clear, logical structure

Formatting	Inconsistent/broken	Mostly consistent	Professional, polished
Usability	Difficult to use	Usable with effort	Easy to use

维度	A（iter-3）	B（iter-4）	胜者
C1 核心创新点位置	5	5	TIE
C2 研究计划表格	3	3	TIE
C3 信息覆盖完整性	4	5	B
C4 章节结构	3	3	TIE
C5 内容丰富度	4	5	B
总分	19	21	B 胜

B 胜的原因：多了 θ=0.85 参数、匈牙利算法/CVAE/PPO
名称、技术栈（FastAPI/Vue.3）、研究现状综述段落。两个版本的共同缺陷：研究

引言 盲测（A=iter-3, B=iter-4）

维度（权重）	A（iter-3）	B（iter-4）	胜者
C1 创新点覆盖（25%）	5	4	A
C2 章节结构（20%）	4	5	B
C3 内容完整性（25%）	5	3	A
C4 列表结构化（15%）	5	4	A
C5 研究计划（15%）	3	4	B
加权得分	4.50	3.95	A 胜

论文：

- **通过率 (Pass Rate)**：这是最核心的基础指标。为了减小随机性，基准测试对每个任务会进行 5 次独立跑分取平均，最后再将所有 84 个评估任务的分数进行总体平均。 +1
- **绝对提升 (Δ_{abs})**：即**“有技能”状态下的通过率**减去**“无技能（基线）”状态下的通过率**，直观展示技能到底带来了多少百分点的性能提升。 +1
- **归一化增益 (Normalized Gain, g)**：为了解决评估中的“天花板效应”（例如，一个模型从 90% 提升到 95%，和另一个模型从 10% 提升到 55%，两者的绝对提升不同，但意义都很大），论文引入了物理教育研究中常用的 Hake 归一化增益公式： +1

$$g = \frac{pass_{skill} - pass_{vanilla}}{1 - pass_{vanilla}}$$

1. 成本与计算效率指标 (Cost and Token Efficiency)

在实际部署智能体时，成本是一个关键因素。论文不仅看模型能不能做对，还看花了多大代价：

- **Token 消耗量 (Token Usage)**：统计了每次试验的平均输入 (Input)、输出 (Output) 和总 Token 数。分析发现，虽然引入 Skills 会增加 6-13% 的输入 Token（针对 Codex 和 Gemini），但其带来的性能提升远超这部分边际成本。 +1
- **单次试验估算成本 (Estimated Cost/Trial)**：根据各个模型的 API 定价计算实际花销。 +1
- **成本-性能帕累托前沿 (Cost-Performance Pareto Frontier)**：评估在相同成本下，使用 Skills 能否带来更高的性价比。例如，Gemini 3 Flash 使用 Skills 后虽然发起了更多轮次的探索（Token 消耗是 Pro 的 2.3 倍），但由于其单价极低，单次任务的成本反而比不带 Skills 的